Summer Training Week2 Report—Retinal Disease Classification

<Diana>

壹、 介紹

在本次實驗中，我使用多種 CNN 模型來建立一個視網膜疾病分類器，本專案主要包含三個部分：

1. 撰寫 Dataloader，將視網膜影像資料載入到 PyTorch 深度學習框架中。
2. 使用不同的 CNN 模型（例如 ResNet18、ResNet50 以及 VGG16）對視網膜影像進行疾病分類。
3. 記錄訓練過程中的 loss 與 accuracy，並透過 wandb 繪製模型的訓練趨勢圖，以分析不同模型與 loss function 的表現。

本實驗所使用的資料集為 RFMiD，每張影像為彩色眼底影像，用來判斷是否具有特定視網膜疾病。每張影像對應到不同的疾病類別，我將標籤轉換為單一分類問題，並進行 6 組實驗，包含不同 CNN 模型、不同 loss function，以及不同超參數設定的比較。

貳、 實驗設定

一、 模型架構

透過比較不同模型的 validation accuracy 與 test accuracy，可以分析模型在視網膜疾病分類任務上的表現差異。本實驗使用多種 CNN 模型進行視網膜疾病分類，包括 ResNet18、ResNet50 與 VGG16。

1. ResNet 介紹

   隨著卷積神經網路的發展，研究發現增加網路深度通常可以提升模型的表現。然而在實際訓練中，當網路層數變得非常深時，模型的訓練誤差反而會上升，這種現象被稱為 degradation problem，是深層網路在訓練時會遇到梯度傳遞困難，使得模型難以學習到良好的參數。

   ResNet 的核心概念是 Residual Learning，其目的是解決深層神經網路在訓練時遇到的 degradation problem，ResNet 引入 shortcut connection，讓輸入可以直接跳過某些層並加到輸出上，這使得模型學習的是殘差函數，而不是直接學習完整的映射。

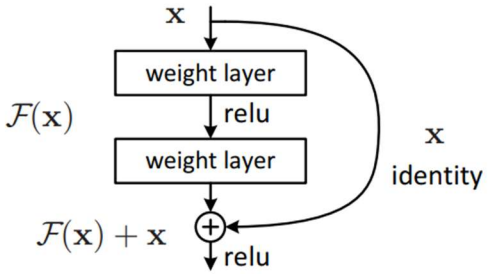

圖 1：ResNet residual block architecture。

每個 Residual Block 主要包含數個 convolution layers 以及一條 shortcut connection。shortcut connection 會將輸入特徵直接與卷積層的輸出相加，形成 residual mapping。由於 shortcut connection 不會增加額外的參數與計算量，因此可以在不增加太多計算成本的情況下，提升深層網路的可訓練性。

ResNet18 與 ResNet50 的主要差異在於 Residual Block 的結構。ResNet18 使用 Basic Block，其結構包含兩個 3x3 convolution layers。ResNet50 則使用 Bottleneck Block，由 1x1、3x3、1x1 convolution layers 所組成。其中 1x1 convolution 主要用於降低與恢復特徵維度，使得網路在增加深度的同時仍能保持較低的計算成本。

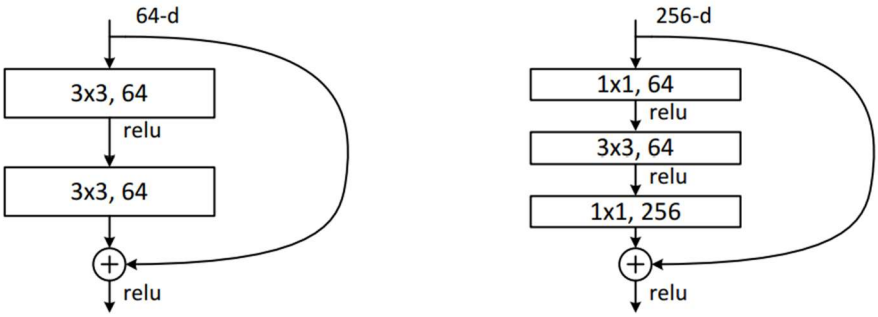

圖 2：Basic Block vs Bottleneck Block。

2. VGG16 介紹

VGG16 的主要特色是使用多層 3x3 的卷積層堆疊來增加網路深度，以提升模型的特徵學習能力，與早期使用較大卷積核的模型相比，使用多個 3x3 卷積層可以在保持相同 receptive field 的情況下減少參數量並增加非線性表達能力。

VGG16 總共有 16 個具有可學習參數的層，包含 13 個卷積層與 3 個全連接層。整體架構由多個 convolution block 組成，每個 block 由數個卷積層與一個 max pooling layer 組成，由於其結構簡單且規律，VGG16 成為許多電腦視覺研究中的基準模型之一。

透過比較不同架構的模型，可以分析不同 CNN 架構在視網膜影像分類任務中的表現差異，我使用 torchvision.models 中的預訓練模型，並修改最後一層分類器，使輸出維度符合資料集的類別數。根據資料集標籤，本實驗

共有 45 個分類類別。

```python
def get_model(model_name: str, num_classes: int):
    model_name = model_name.lower()

    if model_name == "resnet18":
        model = models.resnet18(weights=models.ResNet18_Weights.DEFAULT)
        model.fc = nn.Linear(model.fc.in_features, num_classes)

    elif model_name == "resnet50":
        model = models.resnet50(weights=models.ResNet50_Weights.DEFAULT)
        model.fc = nn.Linear(model.fc.in_features, num_classes)

    elif model_name == "vgg16":
        model = models.vgg16(weights=models.VGG16_Weights.DEFAULT)
        model.classifier[6] = nn.Linear(model.classifier[6].in_features, num_classes)

    else:
        raise ValueError(f"Unsupported model: {model_name}")

    return model
```

圖 3：載入預訓練模型並修改最後一層分類器。

二、 資料集和資料載入器

用 RFMiD 作為資料來源，資料集中包含三個子資料集：Training set、Validation set、Test set， Training set 總共有 1920 張影像，Validation set 和 Test set 各有 640 張影像，每張影像皆為彩色眼底影像，包含 45 種視網膜疾病標籤，用於判斷視網膜疾病類型。資料的標籤存放在 CSV 檔案中，其中：

- 第一欄為影像 ID
- 第二欄為 Disease_Risk
- 後續欄位為疾病的 one-hot 標籤

在 dataloader 中，我將 one-hot label 轉換為單一分類標籤，以進行 single-label classification。

```python
        label_values = row[self.label_cols].astype(float).values
        label = int(label_values.argmax())
```

圖 4：將 one-hot disease label 轉換為 class index。

三、 資料前處理

為了配合 CNN 模型輸入，對影像進行以下前處理：

1. Resize 到 224x224
2. 轉換為 tensor
3. 使用 ImageNet normalization

```python
    transform = transforms.Compose([
        transforms.Resize((args.img_size, args.img_size)),
        transforms.ToTensor(),
        transforms.Normalize([0.485, 0.456, 0.406],
                             [0.229, 0.224, 0.225])
    ])
```

圖 5：資料前處理。

四、 Loss Functions

實驗使用了兩種 loss function，CrossEntropy Loss 是深度學習中最常用於多分類問題的損失函數，它透過比較模型預測的機率分佈與真實標籤之間的差異來計算損失值，當模型對正確類別的預測機率越高時，loss 值就會越小，因此 CrossEntropy Loss 能有效地引導模型學習正確的分類決策。Focal Loss 是為了解決資料集中類別不平衡的問題，Focal Loss 透過在 CrossEntropy Loss 中加入權重$(1-p_t)^{\gamma}$，使模型在訓練過程中更加關注難以分類的樣本，同時降低已經容易分類樣本的影響，這種設計可以在類別分佈不均的情況下提升模型的學習效果。

五、 實驗

共進行了六組實驗：

Experiment	Model	Loss	Learning Rate	Batch Size
Exp1	ResNet18	CrossEntropy	0.0001	16
Exp2	ResNet50	CrossEntropy	0.0001	16
Exp3	VGG16	CrossEntropy	0.0001	8
Exp4	ResNet18	Focal Loss	0.0001	16
Exp5	ResNet18	CrossEntropy	0.001	16
Exp6	ResNet18	CrossEntropy	0.0001	32

參、 實驗結果

一、 訓練曲線

wandb 記錄了每個 epoch 的 training loss、validation loss、training accuracy 與 validation accuracy。

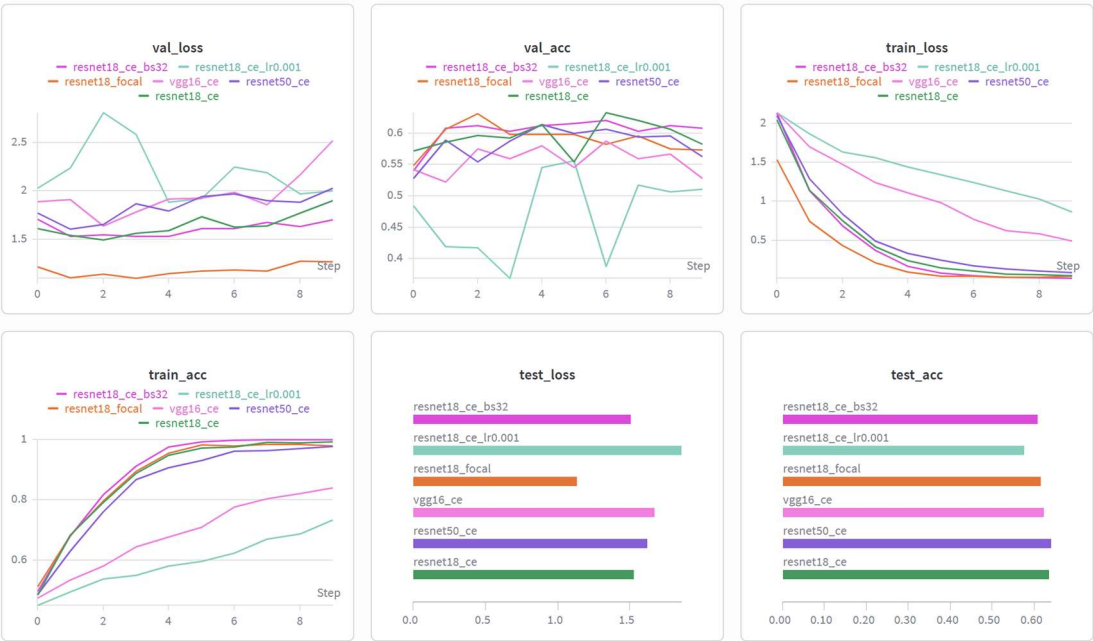

圖 6：不同模型的訓練曲線。

Experiment	Model	Loss	Best Val Acc	Test Acc
Exp1	ResNet18	CrossEntropy	0.6328	0.6359
Exp2	ResNet50	CrossEntropy	0.6141	0.6406
Exp3	VGG16	CrossEntropy	0.5875	0.6234
Exp4	ResNet18	Focal Loss	0.6312	0.6156
Exp5	ResNet18	CrossEntropy	0.5563	0.5766
Exp6	ResNet18	CrossEntropy	0.6203	0.6094

二、 測試集結果

圖 7 顯示不同模型在測試資料集上的表現，其中 ResNet50 在 test accuracy 上取得最佳結果。

圖 7：不同模型的測試集結果。

肆、 討論

一、 模型比較

在本實驗中，若不考慮不同的超參數設定，ResNet 系列模型整體表現優於 VGG16。從實驗結果可以觀察到，ResNet50 在 test accuracy 上取得最佳表現，而 ResNet18 的表現也優於 VGG16。推測是因為 ResNet 引入了 residual connections，使得深層神經網路在訓練過程中能夠更有效地傳遞梯度，減少梯度消失的問題，因此能夠學習到更好的特徵表示。相比之下，VGG16 雖然具有較深的網路結構，但其架構主要是由多層卷積層簡單堆疊而成，缺乏像 ResNet 那樣的 shortcut connection，因此在較深的網路中訓練效率可能較低，此外，VGG16 的參數量也相對較多，可能導致模型在訓練時更容易產生過擬合或學習效率較低的問題，因此在本次視網膜疾病分類任務中，ResNet 系列模型能夠取得較好的分類效果。

二、 Overfitting

從圖 6 的訓練曲線可以觀察到，training accuracy 在訓練過程中逐漸接近 1.0，但 validation accuracy 的提升幅度相對有限，顯示模型存在過

擬合的情況，這代表模型在訓練資料上學習到了非常詳細的特徵，但在未見過的資料上泛化能力有限。造成過擬合的原因推測是資料量不足、模型參數過多，或是訓練輪數過多等因素，在本實驗中，由於使用的是較深的 CNN 模型，例如 ResNet50 與 VGG16，其參數量較大，因此在資料量有限的情況下容易出現過擬合現象。之後可以透過增加資料量、使用資料增強、加入正則化方法，或是調整模型架構與訓練策略，以減少過擬合的問題。

三、 超參數比較

我調整了 learning rate 與 batch size 來觀察超參數對模型表現的影響，圖 8 的結果顯示，不同的 learning rate 會影響模型的收斂速度與最終準確率，而 batch size 的改變則可能影響訓練的穩定性，在實際應用中需要透過不斷實驗來尋找較合適的設定。

圖 8：以 ResNet18+CrossEntropy 為基準模型，比較不同超參數設定。

四、 Loss function 比較

在 ResNet18 的實驗中，我比較了 CrossEntropy Loss 與 Focal Loss 兩種損失函數，從圖 9 可以觀察到，使用 Focal Loss 並沒有提升模型的分類表現，反而在 test accuracy 上略低於使用 CrossEntropy Loss 的結果，造成此現象的可能原因是本資料集的類別不平衡程度並不嚴重，Focal Loss 的設計主要是為了解決資料集中類別極度不平衡的問題，透過增加難分類樣本的權重，使模型更關注這些樣本。然而在本實驗中，資料分佈相對平均，因此使用 CrossEntropy Loss 已經能夠有效地進行分類，導致 Focal Loss 的優勢無法充分展現。此外，Focal Loss 在訓練過程中會降低容易分類樣本的權重，這可能會使模型在部分情況下學習速度變慢，因此在本實驗中未能帶來明顯的性能提升。

圖 9：Focal Loss vs CrossEntropy Loss。